

# Sprawozdanie Projektu

## System rozpoznawania akordów z wykorzystaniem sieci CRNN

Artur Bogusławski, 203279

Wiktor Müller, 203610

Filip Grela, 203850

Karol Obrycki, 203264

## 1. Wstęp i definicja problemu

### 1.1. Kontekst dziedzinowy (Music Information Retrieval)

Rozwój cyfrowego przetwarzania sygnałów oraz sztucznej inteligencji otworzył nowe możliwości w analizie danych dźwiękowych. Prezentowany projekt wpisuje się w prężnie rozwijającą się dziedzinę badawczą znaną jako Music Information Retrieval (MIR), która zajmuje się ekstrakcją wysokopoziomowych informacji (takich jak, tonacja, melodia czy struktura harmoniczna) z niskopoziomowych, surowych sygnałów audio.

### 1.2. Definicja problemu głównego: Automatic Chord Recognition (ACR)

Głównym celem naszego projektu jest rozwiązanie problemu Automatycznego Rozpoznawania Akordów (ACR). Z formalnego punktu widzenia, polega on na stworzeniu systemu zdolnego do podziału utworu muzycznego na segmenty czasowe i przypisania każdemu z nich odpowiedniej etykiety symbolicznej, reprezentującej słyszany w danym momencie akord.

Z perspektywy uczenia maszynowego (Machine Learning) oraz sztucznej inteligencji, zadanie to definiuje się jako **problem klasyfikacji wieloklasowej (multi-class classification) na danych sekwencyjnych (szeregach czasowych)**. Model SI musi nauczyć się skomplikowanego mapowania przestrzeni sygnału ciągłego na dyskretną przestrzeń klas (z góry zdefiniowanego słownika akordów).

### 1.3. Trudności i uzasadnienie wykorzystania metod AI

Skonstruowanie deterministycznego, opartego na sztywnych regułach algorytmu do rozpoznawania akordów jest zadaniem praktycznie niemożliwym. Złożoność problemu wynika z kilku fundamentalnych cech muzyki:

- **Polifonia i nakładanie się dźwięków:** W typowym utworze muzycznym jednocześnie brzmi wokal, gitary, instrumenty klawiszowe i bas. Separacja tych źródeł jest niezwykle trudna.
- **Obecność instrumentów perkusyjnych:** Perkusja i szumy tła (dźwięki nieharmoniczne) zakłócają widmo częstotliwościowe, wprowadzając szerokopasmowy hałas utrudniający detekcję tonów.
- **Zjawisko alikwotów (tonów harmoniczných):** Instrumenty akustyczne generują oprócz tonu podstawowego również szereg wyższych częstotliwości harmoniczných. Mogą one zostać błędnie zinterpretowane przez proste algorytmy jako dźwięki należące do innych akordów.
- **Zróżnicowanie barwy i artykulacji:** Ten sam akord (np. C-dur) brzmi zupełnie inaczej na pianinie, gitarze akustycznej czy przesterowanej gitarze elektrycznej.

## 1.4. Cel projektu

Biorąc pod uwagę złożoność analizy sygnałów dźwiękowych, głównym celem projektu było zaprojektowanie kompletnego rurociągu (pipeline'u) uczenia maszynowego, który samodzielnie wyekstrahuje ukryte wzorce i zależności muzyczne z dużego zbioru danych. Działamy w przestrzeni operacyjnej, która mapuje ciągły, niskopoziomowy sygnał audio (transformowany do precyzyjnych spektrogramów CQT) na dyskretną przestrzeń symboliczných etykiet akordowych w dziedzinie czasu. Ostatecznym rezultatem jest sztuczna sieć neuronowa (CRNN) zdolna do generalizacji i skutecznego klasyfikowania struktury harmoniczných w nieznaných wcześniej utworach.

Aby system mógł skutecznie uczyć się z danych, przestrzeń problemu została ściśle zdefiniowana i zoptymalizowana pod kątem kilku kluczowych założeń:

**1.4.1. Zdefiniowana przestrzeń klas (Słownik akordów)** System został zaprojektowany tak, aby konfigurowalnie wspierać różne rozmiary słownika akordów. Architektura przewiduje dwa główne tryby:

- **Przestrzeń rozszerzona (49 klas):** Obejmuje 12 podstawowych akordów durowych (major), 12 molowych (minor), ich odpowiedniki z septymą (12 akordów dominantowych septymowych i 12 molowych septymowych) oraz jedną klasę reprezentującą brak akordu/ciszę ('N').
- **Przestrzeń zredukowana (25 klas):** Ogranicza się wyłącznie do 12 trójdźwięków durowych, 12 trójdźwięków molowych oraz klasy 'N'. Jak dowiodły nasze eksperymenty, to właśnie ta uproszczona przestrzeń pozwoliła na osiągnięcie najwyższej skuteczności (model lepiej generalizuje bazowe harmonie, nie gubiąc się w subtelnych interwałach).

**1.4.2. Redukcja i obsługa akordów spoza zdefiniowanej przestrzeni (Out-of-Vocabulary)** Utwory muzyczne w zbiorach danych zawierają niezwykle bogatą notację (np. akordy zawieszone, zwiększone, z dodaną noną czy przewroty). Ponieważ model operuje na zamkniętym słowniku klas, zaimplementowano dedykowany moduł parsujący, który standaryzuje etykiety w sposób bezstratny dla ogólnego kontekstu harmoniczných:

- **Ignorowanie przewrotów (basu):** Wszelkie akordy łamane (np. *C/E*) są upraszczane do ich głównego korzenia (zostaje samo *C*).
- **Redukcja rozszerzeń:** Akordy z dodatkowymi składnikami, takimi jak nony czy terdecymy, są sprowadzane do najbliższej wspieranej formy (np. *Cmaj9* staje się zwykłym *Cmaj*).
- **Mapowanie jakości:** Akordy zmniejszone (*dim*) są rzutowane na ich molowe odpowiedniki (np. *Cdim* -> *Cm*), ponieważ zachowują kluczową dla trybu małą tercję.
- **Klasa 'N' jako śmietnik szumów:** Wszelkie partie perkusyjne, absolutna cisza, dźwięki mowy lub nierozpoznawalny hałas są przypisywane do osobnej klasy 'N' (No-chord).

**1.4.3. Muzyczna świadomość modelu (Music-Aware Loss)** Celem projektu nie była zwykła, sztywna klasyfikacja. W standardowych sieciach pomyłka między akordem *C-dur* a *C-moll* jest karana tak samo surowo, jak pomyłka między *C-dur* a skrajnie niepasującym *F#-dur*. W naszym rozwiązaniu wdrożyliśmy innowacyjną funkcję straty (SoftLabelLoss). Opiera się ona na macierzy podobieństwa akordów wyliczanej m.in. na podstawie odległości na kole kwintowym oraz tożsamości trybu i rdzenia. Dzięki temu model "rozumie" teorię muzyki - uczy się, że błędy w obrębie pokrewnych akordów są naturalne, a dysonanse są surowo karane.

**1.4.4. Reprezentacja i kontekst czasowy** Zamiast analizować spektrogram klatka po klatce, celem sieci było zrozumienie następstwa akordów. Architektura dzieli utwór na tzw. przesuwne okna czasowe (sliding windows) o stałej długości (np. 86 ramek). Ponadto, zastosowany w sieci autorski mechanizm uwagi (Attention Block) pozwala modelowi zignorować chwilowe zakłócenia perkusyjne wewnątrz takiego okna i skupić swoje "spojrzenie" wyłącznie na tych momentach czasowych, w których najmocniej wybrzmiewa dany układ harmoniczny.

## 2. Globalne podejścia do Automatycznego Rozpoznawania Akordów (ACR)

Problem automatycznej ekstrakcji harmonii z sygnału audio jest jednym z fundamentalnych zagadnień w globalnej dziedzinie Music Information Retrieval (MIR). Na przestrzeni ostatnich lat podejście do tego problemu uległo znaczącej ewolucji, przechodząc od klasycznych metod opartych na czystym przetwarzaniu sygnałów (DSP), aż po nowoczesne architektury Głębokiego Uczenia (Deep Learning).

### 2.1. Standardowe podejście do problemu

Obecnie w systemach ACR stosuje się najczęściej architekturę dwuetapową:

- **Ekstrakcja cech (Front-end):** Zamiast analizować surową falę dźwiękową, badacze korzystają z transformat czasowo-częstotliwościowych o skali logarytmicznej. Powszechnym standardem stała się transformata CQT (Constant-Q Transform) i

oparte na niej chromagramy, ponieważ najlepiej oddają to, jak ludzkie ucho odbiera wysokości dźwięków.

- **Modelowanie kontekstu (Back-end):** Dawniej do wygładzania przejść między akordami używano Modeli Ukrytych Markowa (HMM) - opierał się na nich np. popularny algorytm *Chordino*. Dziś zastąpiły je głębokie sieci neuronowe, które potrafią skuteczniej analizować kontekst i zapamiętywać relacje harmoniczne na dłuższych odcinkach czasu.

## 2.2. Przykładowe rozwiązanie ze świata (State-of-the-Art)

Dobrym przykładem nowoczesnego podejścia jest architektura BTC (Bi-directional Transformer for Chord Recognition), opracowana przez zespół badawczy z Seulskiego Uniwersytetu Narodowego (SNU) w Korei Południowej (Jonggwon Park i in.). Rozwiązanie to wyznacza obecne standardy i opiera się na następujących założeniach:

- **Dane wejściowe:** Model wykorzystuje czyste CQT, rezygnując z klasycznych chromagramów. Autorzy zastosowali też augmentację danych przez transpozycję (przesuwanie widma o półtony), dzięki czemu sieć radzi sobie z nagraniami w różnych tonacjach, co jest kluczowe w muzyce.
- **Architektura sieci:** Zamiast warstw rekurencyjnych (jak RNN czy LSTM), wykorzystano mechanizm *Self-Attention* znany z modeli typu Transformer. Dzięki temu algorytm może powiązać ze sobą akordy z różnych części piosenki i np. zauważyć, że refren w 3. minucie ma strukturę spójną z początkiem utworu.
- **Radzenie sobie z szumem:** Instrumenty perkusyjne naturalnie zakłócają widmo. W oryginalnym modelu BTC problem ten zostawiono do rozwiązania wewnętrznym warstwom konwolucyjnym sieci. Jednak w nowszych badaniach z tego nurtu coraz częściej odfiltrowuje się uderzenia jeszcze na etapie DSP (np. algorytmem HPSS), co pokrywa się z założeniami naszego projektu.

## 2.3. Nasz projekt na tle globalnych trendów

System *AI-Chord-Analysis* wprost odpowiada na omówione wyżej wyzwania. Architektura hybrydowa (CRNN), którą zastosowaliśmy, to sprawdzone podejście. Na etapie przetwarzania DSP wykorzystujemy filtr HPSS oraz zoptymalizowaną wektorowo transformatę CQT, co pozwala uzyskać bardzo precyzyjne dane wejściowe. Z kolei w samym modelu używamy dwukierunkowych warstw GRU wzbogaconych o autorski blok *Attention* oraz "muzycznie świadomą" funkcję straty (*Music-Aware Loss*). Pozwala to na zminimalizowanie zjawiska sztucznego rwania sekwencji akordów (tzw. migotania) i dobrze wpisuje się w nowoczesne metody analizy harmonii.

## 3. Przebieg prac nad projektem

### 3.1. Proof of Concept i pierwsze wizualizacje

Prace nad systemem rozpoczęliśmy od zbadania możliwości przekształcenia surowego sygnału audio na reprezentację wizualną, którą mogłaby przeanalizować sieć neuronowa. Pierwszym krokiem było stworzenie tzw. *Proof of Concept* (PoC) z wykorzystaniem gotowych narzędzi biblioteki Librosa do generowania podstawowych spektrogramów.

Gdy upewniliśmy się, że ekstrakcja cech działa poprawnie, stworzyliśmy podstawowy interfejs graficzny użytkownika (GUI). Pozwalał on na wygodne wyświetlanie wygenerowanych spektrogramów, co było kluczowe do optycznego weryfikowania, czy w danych nie ma błędów i czy wzorce akordów są widoczne gołym okiem. Efekty przedstawiono poniżej na *zdjęciu 1.1*

### 3.2. Budowa wczesnego datasetu i bazowy model sieci

Kolejnym etapem było przygotowanie potoku przetwarzania danych (ETL) oraz wczesnego zbioru treningowego. Na start użyliśmy małej próbki około 200 piosenek.

Początkowo ograniczyliśmy przestrzeń problemu do 25 klas (12 akordów durowych, 12 molowych oraz klasa 'N' oznaczająca ciszę/brak akordu). Architektura kodu została jednak od razu zaprojektowana tak, aby przyszłe rozszerzenie puli klas (np. o akordy septymowe) polegało wyłącznie na zmianie pojedynczej flagi w konfiguracji, bez konieczności przepisywania logiki modelu.

Nasz pierwszy model weryfikowaliśmy przy pomocy standardowej, twardej funkcji straty (kategoryczna entropia krzyżowa). Na tym etapie sieć oceniała predykcję wyłącznie w kategoriach absolutnego sukcesu lub całkowitej porażki, bez uwzględniania złożonych, muzycznych podobieństw między akordami. Równolegle zoptymalizowaliśmy tensorowe operacje modelu, aby w pełni wykorzystywały akcelerację sprzętową GPU.

Wyniki pierwszego w pełni działającego modelu wyniosły około 59% skuteczności na zbiorze 200 piosenek:

- **Train Loss:** 1.5161 (Acc: 59.18%)
- **Val Loss:** 1.5909 (Acc: 59.71%)

*Skomentarze:* Działanie pierwszego modelu przypominało ucznia w szkole muzycznej, który uczy się rozpoznawać dźwięki na zasadzie "zgadłem / nie zgadłem", nie rozumiejąc jeszcze, dlaczego pomylił C-dur z bardzo podobnym brzmieniowo C-moll.

### 3.3. Optymalizacja wejścia - autorskie filtry DSP (CQT i HPSS)

Aby przebić barierę 59% skuteczności, konieczna była radykalna poprawa jakości danych wejściowych. Zamiast polegać na standardowej krótkoczasowej transformacie Fouriera (STFT), wdrożyliśmy własnoręczną transformatę - **CQT (Constant-Q Transform)**. Standardowe STFT posiada liniowy rozkład częstotliwości, co jest nienaturalne dla muzyki (oktawa w niskich rejestrach zajmuje zaledwie kilkadziesiąt herców, podczas gdy w wysokich tysiące herców). CQT mapuje częstotliwości logarytmicznie. Dzięki temu każdy półton w muzyce otrzymuje dokładnie taką samą szerokość (w naszym systemie są to 3 biny na półton, co daje 36 binów na oktawę). Dzięki temu sieć neuronowa widzi identyczny wizualny odstęp między dźwiękami C i D, niezależnie od tego, w jakiej oktawie są zagrane.


Dodatkowo zaimplementowaliśmy zoptymalizowany filtr **HPSS (Harmonic-Percussive Source Separation)**. Uderzenia bębnow i talerzy wprowadzają do widma szerokopasmowy szum, który zamazuje częstotliwości dźwięków. HPSS wykorzystuje medianowe filtrowanie w dwóch osiach (czasu i częstotliwości), pozwalając całkowicie "wyciąć" perkusję z nagrania i pozostawić do analizy tylko czyste, brzmiące akordy.

Efekty widoczne są na zdjęciach poniżej:




*Zdj 1.1.: Spektrogram przed zmianami*

CQT Spectrogram (252 bins/octave=36) - Hover to read notes



Zdj 1.2.: Spektrogram wygenerowany z użyciem własnoręcznej transformaty oraz hpss. 252 biny.

CQT Spectrogram (84 bins/octave=12) - Hover to read notes



Zdj 1.2.: Spektrogram wygenerowany z użyciem własnoręcznej transformaty oraz hpss. 84 biny.



### 3.4. Augmentacja danych (Online i Offline)

Kolejnym krokiem do poprawy skuteczności była augmentacja danych, czyli technika sztucznego namnażania i modyfikowania przykładów treningowych. Zastosowaliśmy dwa podejścia:

1. **Offline:** Przekształcenia wykonywane raz, trwale zapisywane na dysku. W tym trybie zaimplementowaliśmy transpozycję (przesunięcie całego utworu o konkretną liczbę półtonów z jednoczesną zmianą jego etykiet).
2. **Online (w locie):** Przekształcenia aplikowane losowo w ułamku sekundy podczas podawania danych do sieci. Dzięki temu w każdej z kilkudziesięciu epok treningowych sieć "widziała" tę samą piosenkę w nieco innej, zdeformowanej formie.

Napisaliśmy 4 główne filtry augmentacyjne typu online:

- **Random Gain:** Losowa zmiana głośności, przygotowująca model na nagrania o różnej dynamice.
- **Additive Gaussian Noise:** Nakładanie cyfrowego szumu bezpośrednio na spektrogram.
- **Random SpecMask:** Losowe "wyciszanie" pionowych lub poziomych bloków spektrogramu, co zmusza sieć do zgadywania akordu nawet wtedy, gdy brakuje części częstotliwości (np. gdy basista przestał grać).
- **Random Transpose:** Transpozycja w locie.

Implementacja tak wielu filtrów wprowadziła nagle niemal 20 nowych hiperparametrów do regulacji (prawdopodobieństwa nałożenia, wartości min/max szumu, szerokość masek). Aby zachować kontrolę nad eksperymentami, zrezygnowaliśmy z niektórych mniej wpływowych zmiennych, optymalizując proces treningowy. Samo wprowadzenie tych filtrów zwiększyło skuteczność klasyfikacji o blisko 8 punktów procentowych.

### 3.5. Skalowanie zbioru i potężna analityka (1000 utworów)

Zdając sobie sprawę, że głębokie sieci neuronowe są głodne danych, zdecydowaliśmy się drastycznie zwiększyć nasz dataset z 200 do niemal 1000 wyselekcjonowanych i opisanych piosenek. Po ponownym wytrenowaniu modelu na powiększonym zbiorze i czystym sygnale z CQT i HPSS, nasza skuteczność na zbiorze testowym przebiła barierę **70%** (dla 25 klas / trójdźwięków).

Aby dogłębnie zrozumieć, dlaczego model osiągnął taki wynik i w jakich miejscach wciąż się myli, zaprojektowaliśmy kompleksowy system generowania metryk (zdefiniowany w modułach analitycznych). Dodaliśmy wyliczanie zaawansowanych parametrów (m.in. *Chord Error Rate* mierzący płynność przejść, skuteczność detekcji samej prymy oraz trybu) oraz automatyczne generowanie wykresów, takich jak macierz pomyłek czy zależności skuteczności od liczności próbek (support vs performance).



### 3.6. Eksperymenty z rozszerzoną przestrzenią klas (Akordy septymowe)

Osiągnięcie stabilnych 70% dało nam podstawę do sprawdzenia możliwości modelu na znacznie wyższym poziomie trudności. Włączyliśmy w konfiguracji flagę odpowiedzialną za akordy septymowe. Wymagało to dynamicznego rozszerzenia przestrzeni sieci z 25 do 49 klas, zaktualizowania słownika akordów oraz zaimplementowania logiki parsowania potrafiącej wyciągnąć informacje o dodatkowych interwałach z surowych etykiet tekstowych. Porównanie osiągnięć modelu na podstawowych trójdźwiękach względem trudniejszych akordów septymowych stało się fundamentem naszej końcowej ewaluacji. Szczegółowe efekty tych eksperymentów, poparte zrzutami z wygenerowanych wykresów analitycznych, prezentujemy w kolejnych podrozdziałach.

## 4. Opis działania projektu

### 4.1 Przetwarzanie piosenek

Projekt przetwarza czyste MP3 do danych treningowych w kilkietapowym pipeline'ie DSP. Najpierw *AudioProcessor* (*dsp/spectrograms.py*) dekoduje audio przez FFmpeg do mono 44.1 kHz, po czym filtr HPSS (*dsp/src/hpssFilterOptimized.py*) **separuje składową harmoniczną od perkusyjnej**. Następnie własna implementacja Constant-Q Transform (*dsp/src/cqtTransform.py*) generuje spektrogram o 252 pasmach częstotliwościowych (36 pasm na oktavę, 7 oktav od C1=32.7 Hz), po czym sygnał jest normalizowany do skali decybelowej, kompresowany do zakresu 35 dB i skalowany do 0,1. W *DatasetBuilder* (*data/builder.py*) spektrogram jest cięty na nakładające się okna o długości **86 ramek (~8 sekund) z krokiem 10 ramek**, a etykieta każdego okna pochodzi z centralnej ramki. Równolegle *ChordLabelParser* (*data/parser.py*) parsuje i normalizuje etykiety akordów z plików JAMS/CSV - akordy septymowe, molowe, durowe, zmniejszone i enharmoniczne są sprowadzane do ujednoliconego słownika. W zależności od flagi *SUPPORT\_SEVENTHS*, słownik liczy 25 klas (12 durowych, 12 molowych, cisza N) lub 49 klas (dodatkowo 12 dominant septymowych i 12 molowych septymowych). Podczas budowania datasetu w tle działa augmentacja online (*data/augment/*) - losowe wzmocnienie, maskowanie pasm, szum gaussowski i transpozycja - zwiększająca odporność modelu.

## 4.2 Trenowanie

Trenowanie nowego modelu opiera się na PyTorchu z akceleracją CUDA. Architektura *ChordCRNN* (*models/crnn.py*) składa się z trzech warstw konwolucyjnych (32→64→128 kanałów) oraz bloku uwagi, który uczy się wagować istotność poszczególnych ramek czasowych przed klasyfikatorem liniowym. **Model trenuje się przez maksymalnie 50 epok** z wczesnym zatrzymaniem (*patience*=15), używając optymalizatora AdamW (*lr*=1e-4, *weight\_decay*=5e-4) i harmonogramu *ReduceLROnPlateau*. Funkcja straty *SoftLabelLoss* (*training/loss.py*) łączy ważoną klasowo entropię krzyżową (70%) z muzycznie świadomą dywergencją KL (30%) - macierz podobieństwa akordów uwzględnia dopasowanie prymy (55%), trybu dur/mol (30%), rozszerzeń septymowych (10%) i odległości w kole kwintowym (15%), dzięki czemu model nie jest nadmiernie karany za "muzycznie bliskie" pomyłki. Dataset jest dzielony na trening/walidację w proporcji **85/15** na poziomie całych utworów.

## 5. Rozwój Architektury i Analiza Eksperymentów

Proces optymalizacji modelu klasyfikującego akordy wymagał zbalansowania trzech kluczowych czynników: zdolności sieci do precyzyjnego analizowania częstotliwości, szerokości kontekstu historycznego oraz odporności na przeuczenie. Historia ewolucji architektury dzieli się na trzy główne etapy, które doprowadziły system od podstawowego wariantu do w pełni zgeneralizowanego rozwiązania produkcyjnego.

### 5.1 Poprawa percepcji i rozszerzenie kontekstu muzycznego

Pierwszy etap prac skupił się na dostarczeniu sieci głębokiej znacznie bogatszej i czystszej reprezentacji dźwięku. Początkowy model bazowy, osiągający dokładność na poziomie 58.07%, analizował spektrogramy o niskiej rozdzielczości (84 biny) w wąskich, około dwusekundowych oknach czasowych. Zasadniczy przełom nastąpił po potrojeniu rozdzielczości widma do 252 binów (36 binów na oktawę) oraz wydłużeniu okna analizy do niespełna 8 sekund (86 ramek co 93 ms). Jednocześnie włączono filtr HPSS, usuwający z sygnału zakłócenia perkusyjne, oraz zredukowano warstwy sieci rekurencyjnej z czterech do dwóch, co zapobiegło zjawisku zanikającego gradientu i redukcji szumu z danych treningowych. Te zmiany pozwoliły modelowi precyzyjnie identyfikować drobne różnice interwałowe i poprawnie wnioskować o harmonii na podstawie dłuższego kontekstu przed i po badanym dźwięku. Zaowocowało to najwyższą odnotowaną dokładnością rzędu 69.53% dla podstawowego słownika 25 klas. Zarejestrowana macierz pomyłek oraz wykresy metryk ewaluacyjnych dla tego wariantu modelu idealnie obrazują ten sukces, prezentując silnie zarysowaną przekątną trafień i bardzo wysokie wartości precyzji dla najpopularniejszych akordów, takich jak C-dur czy G-dur.


## 5.2 Koszt szczegółowości i rozszerzenie słownika o akordy septymowe

Kolejnym krokiem w rozwoju projektu było podniesienie poprzeczki i uaktywnienie obsługi akordów septymowych, co poszerzyło docelową przestrzeń klasyfikacyjną z 25 do 49 klas. Jak przewidywano, drastycznie zwiększyło to poziom trudności zadania, co miało bezpośrednie odzwierciedlenie w spadku globalnej dokładności z około 69.5% do poziomu 49.00%. Spadek ten nie oznacza jednak degradacji samego modelu, lecz jest naturalnym efektem akustycznej subtelności wprowadzonych rozszerzeń i kłóty wielowymiarowości. Akordy trójdźwiękowe i ich septymowe warianty (np. a-moll i a-moll 7) różnią się często zaledwie jednym dźwiękiem w wyższym rejestrze, wysoce podatnym na maskowanie przez wokale lub przesterowane gitary w gęstym miksie. Analizując rozkład skuteczności oraz macierz pomyłek dla modelu z rozszerzonym słownikiem, można zaobserwować zjawisko tak zwanych "miękkich pomyłek". Precyzja dla fundamentalnych trójdźwięków utrzymała się na stabilnym poziomie, podczas gdy błędy zaczęły koncentrować się na rozmyciu prawdopodobieństwa w obrębie klas ściśle pokrewnych harmonicznie.


## 5.3 Przełamywanie błędu statystycznego poprzez transpozycję offline

Ostatnia, kluczowa z perspektywy produkcyjnej faza, polegała na walce z tendencją sieci do uczenia się na pamięć rozkładu tonacji w zbiorze treningowym. Zdecydowana większość popularnych utworów opiera się na prostych tonacjach, co sztucznie zawyża metryki modelu "zgadującego" najczęstsze akordy z samego prawdopodobieństwa statystycznego. Aby wyeliminować to obciążenie (tzw. key bias), wprowadzono agresywną augmentację w postaci transpozycji offline w szerokim zakresie od -4 do +4 półtonów. Wymusiło to na systemie weryfikację tych samych utworów w rzadkich, trudnych tonacjach. Zastosowanie tej zmiany doprowadziło do natychmiastowego spadku surowych metryk walidacyjnych: z 69.53% na 59.00% w przypadku trójdźwięków oraz z 49.00% na 47.00% dla pełnego słownika z septymami. Równocześnie zaobserwowano radykalne przyspieszenie zjawiska wczesnego zatrzymywania uczenia (early stopping), które następowało już w okolicach 5. i 7. epoki. Oznacza to, że sieć szybko poddawała się w próbach zapamiętywania konkretnych utworów i skupiała się wyłącznie na uniwersalnych relacjach interwałowych. Zarówno analiza wyników dla modelu z podstawowym słownikiem trójdźwięków (59% dokładności), jak i dla jego wariantu rozszerzonego o akordy septymowe (47% dokładności) - obu trenowanych z włączoną transpozycją - pokazuje wyraźne spłaszczenie rozkładu skuteczności. Różnice w dokładności pomiędzy popularnymi a niszowymi tonacjami uległy w nich mocnemu zatarciu, tworząc znacznie bardziej sprawiedliwy rozkład.


### Rozkład per class dla danych modeli:




Zdj. 2.1.: Akordy septymowe  
transpozycja  $\pm 4$ . Skuteczność 47%



Zdj. 2.1.: Akordy septymowe  
brak transpozycji. Skuteczność 49%



Zdj. 2.3.: Akordy trójdźwiękowe  
transpozycja  $\pm 4$ . Skuteczność 59%



Zdj. 2.4.: Akordy trójdźwiękowe  
brak transpozycji. Skuteczność 69%

W perspektywie inżynierskiej to właśnie model osiągający "zaledwie" 47% dokładności - obsługujący 49 klas i trenowany na zbiorze poddanym transpozycji - stanowi ostateczne, najbardziej dojrzałe rozwiązanie w projekcie. Zrezygnowano w nim z wysokich wskaźników testowych na rzecz najwyższej odporności na całkowicie nowe pliki audio oraz realnej zdolności do generalizacji wiedzy muzycznej w środowisku produkcyjnym.

## 6. Wynik

### 6.1. Transpozycje i akordy septymowe


W trakcie prac ewaluacyjnych przetestowaliśmy cztery kluczowe warianty modelu CRNN, modyfikując rozmiar słownika akordów, wielkość okna kontekstowego oraz stosując augmentację danych.

- **Model 1 (Bazowy):** Słownik rozszerzony o akordy septymowe, brak transpozycji. Dokładność: **46%**.
- **Model 2 (Najlepszy wynik):** Ograniczenie słownika do 25 klas (tylko akordy major/minor + klasa N), znacznie powiększone okno kontekstu (dłuższa sekwencja analizowana jednocześnie), brak transpozycji. Dokładność: **69,53%**.
- **Model 3:** Słownik 25 klas, dodana augmentacja przez transpozycję danych. Dokładność: **59%**.
- **Model 4:** Akordy septymowe włączone, dodana transpozycja danych. Dokładność: **47%**.

Z powyższych prób wynika, że największy skok jakościowy przyniosło **wydłużenie okna kontekstowego**. Dowodzi to, że do prawidłowej klasyfikacji akordu sieć rekurencyjna potrzebuje szerszej informacji o strukturze czasowej utworu. Z kolei wyłączenie z detekcji akordów septymowych znacząco ustabilizowało model - przy obecnym rozmiarze datasetu sieć świetnie radzi sobie z podstawowymi triadami, lecz ma trudności z subtelными różnicami wprowadzanymi przez dodatkowe interwały (np. septymy).

Choć włączenie augmentacji przez transpozycję obniżyło wyniki na zbiorze walidacyjnym (spadek z 69% do 59%), nie oznacza to definitywnego pogorszenia jakości systemu. Rozszerzony w ten sposób dataset uniemożliwił modelowi szybkie przeuczenie się (overfitting) na znanych mu utworach, zmuszając go do nauki relacji interwałowych, a nie "pamięciowego" uczenia się konkretnych częstotliwości piosenek.

## 6.2. Szczegółowa analiza najlepszego modelu (Macierz pomyłek)



Aby dokładnie zrozumieć skuteczność i słabe strony naszego najlepszego modelu (Model 2: 69,53%), wygenerowaliśmy i przeanalizowaliśmy macierz pomyłek (ang. *Confusion Matrix*) dla 25 klas (12 durowych, 12 molowych oraz klasa 'N' oznaczająca ciszę lub szum).


Analiza macierzy dostarcza kilku kluczowych wniosków, które potwierdzają, że błędy popełniane przez sieć mają uzasadnienie muzyczne:

- **Wysoka skuteczność na przekątnej:** Główna przekątna macierzy wyraźnie dominuje (ciemne pola), co oznacza, że model bardzo dobrze przyswoił mapowanie cech dla większości klas. Najwyższą skuteczność osiągnięto dla akordów takich jak **Cm (81%)**, **D# (79%)**, **Bm (78%)** oraz **E i G (odpowiednio 77% i 76%)**.
- **Błędy trybu (Major vs Minor):** Sieć czasami poprawnie rozpoznaje dźwięk podstawowy (prymę) akordu, ale myli jego tryb (dur/mol). Przykładowo, akord **Em** jest w **30%** przypadków błędnie klasyfikowany jako **E** (dur). Podobnie **D#m** jest mylony z **D#** w **19%** przypadków. Wynika to z faktu, że akordy jednoimienne różnią się tylko jednym dźwiękiem (tercją wielką lub małą), co w gęstym miksie audio bywa trudne do odseparowania.
- **Błędy pokrewieństwa tonacji (Relative Chords):** Model wykazuje skłonność do mylenia akordów, które współdzielą większość dźwięków (akordy równoległe). Najwyraźniej widać to na przykładzie akordu **A#m** (dźwięki: A#, C#, F), który w **20%**

przypadków rozpoznawany jest jako **C#** (dźwięki: C#, F, G#). Sieć wykrywa wspólne częstotliwości (C# i F) i klasyfikuje próbkę na korzyść częściej występującej klasy. Podobnie akord **Dm** jest mylony z **F** (12%).

- **Problem z klasą N (Cisza / Dźwięki nieharmoniczne):** Klasa 'N' osiągnęła najniższą trafność - zaledwie **29%**. Sieć rzadko poprawnie wykrywa brak akordu, mając tendencję do klasyfikowania szumów, uderzeń perkusji lub cichego tła jako popularne akordy durowe, takie jak **G (22%)**, **D (22%)** czy **C (10%)**. Ma to związek z małą ilością próbek dla klasy N w danych treningowych, przez co model miał trudność z jej późniejszym rozpoznawaniem. Pokazuje to, jak duży wpływ na jakość predykcji mają szerokopasmowe zakłócenia perkusyjne i alikwoty.

### 6.3. Szczegółowa analiza wskaźników klasyfikacyjnych (Precision, Recall, F1-Score)





Aby pogłębić ewaluację najlepszego modelu (25 klas, bez transpozycji offline), przeanalizowano rozkład trzech kluczowych metryk statystycznych dla każdego akordu: **Precyzji (Precision)**, **Czułości (Recall)** oraz będącego ich średnią harmoniczną wskaźnika **F1-Score**. Analiza wykresu słupkowego pozwala na wyciągnięcie szczegółowych wniosków dotyczących tego, jak sieć radzi sobie z konkretnymi tonacjami, gdzie jest zbyt "pewna siebie", a gdzie unika odpowiedzi.



- **Dominacja silnych trybów (Wysoki wskaźnik F1):** Dla znacznej większości klas akordów (zarówno durowych, jak i molowych) wskaźnik F1 oscyluje w bardzo zadowalających granicach **0.65 - 0.80**. Absolutnym faworytem modelu okazał się akord **Cm**, dla którego wskaźnik F1, jak i Precyzja przekroczyły próg 0.80. Równie stabilnie rozpoznawane są akordy **G#**, **A**, **E** oraz **C#m**. Dowodzi to, że dla najczęściej występujących interwałów model osiągnął wysoki poziom pewności i generalizacji.
- **Zjawisko nadinterpretacji - niska precyzja, wysoka czułość (False Positives):** Bardzo ciekawym zjawiskiem na wykresie jest przypadek akordu **Fm**. Jego wskaźnik Czułości (Recall) jest stosunkowo wysoki (ponad 0.60), jednak Precyzja (Precision) drastycznie spada poniżej 0.40. Oznacza to, że model wykazuje skłonność do tzw. nadreprezentacji tej klasy - bardzo często "zgaduje", że słyszy akord Fm w momentach, gdy w rzeczywistości gra coś zupełnie innego (generuje dużo fałszywie pozytywnych wyników). Może to wynikać z nałożenia się częstotliwości wokalnych na konkretne przedziały binów CQT powiązanych z trybem Fm w zbiorze treningowym.
- **Problem niedoreprezentacji - wysoka precyzja, niska czułość (False Negatives):** Z odwrotną sytuacją mamy do czynienia w przypadku niektórych rzadszych akordów, takich jak **B** czy **F#m**. Model osiąga w ich przypadku relatywnie wysoką Precyzję w stosunku do Czułości. Wynika z tego, że sieć jest wysoce konserwatywna - klasyfikuje okno jako akord B tylko wtedy, gdy jest tego absolutnie pewna, przez co omija (nie wykrywa) wielu rzeczywistych wystąpień tych akordów w utworach.
- **Marginalizacja klasy N (Szum / Brak akordu):** Wykres słupkowy idealnie potwierdza wnioski wyciągnięte wcześniej z macierzy pomyłek. Klasa **N** charakteryzuje się najniższym wskaźnikiem F1 (ok. 0.38). Co istotne, jej Czułość (Recall) wynosi zaledwie niecałe 0.30. Oznacza to, że model ma ogromny problem z detekcją "pustych" przebiegów i ciszy - w ponad 70% przypadków braku akordu sieć "na siłę" dopasowuje zasłyszany szum sprzętu lub bębny perkusji do najbliższego znanego jej akordu z tonacji głównej utworu.

## 6.4. Wpływ liczebności klas na stabilność modelu

W celu dogłębnego zrozumienia zachowania sieci, przeanalizowano korelację pomiędzy liczbą dostępnych przykładów treningowych dla danej klasy (Support) a osiąganą przez nią precyzją (Accuracy). Dwuwymiarowe wykresy liniowo-słupkowe ewidentnie obnażają wrażliwość modelu na asymetrię w rozkładzie zbioru danych.



- **Stabilność w strefie wysokiej reprezentacji:** Lewa strona wykresów (dla klas o wsparciu sięgającym od 8 000 do ponad 25 000 próbek) charakteryzuje się bardzo stabilnym przebiegiem czerwonej linii dokładności. Klasy te – reprezentujące najpopularniejsze trójdźwięki w muzyce popularnej (np. C, G, D, F#) – dostarczają sieci wystarczającej ilości wariacji (różne instrumenty, wokale, tempo), aby model mógł wyodrębnić solidne, uniwersalne wzorce i pewnie klasyfikować dźwięki.
- **Chaotyczność i degradacja dla klas rzadkich:** Prawa strona wykresu rozszerzonego (model 49-klasowy z septymami) obrazuje drastyczny spadek liczby próbek poniżej 3 000 dla trudniejszych akordów molowych oraz septymowych (np. D#m, Fm, B7, Dm7). W tej strefie krzywa skuteczności zaczyna gwałtownie oscylować, tworząc głębokie doliny i losowe piki. Udowadnia to, że model przy niedoborze danych gubi się, nie potrafiąc wyabstrahować reguł harmoniczných, a jego predykcje stają się wysoce niestabilne.
- **Marginalizacja trudnych interwałów:** Zauważalny jest fakt, że niemal wszystkie akordy septymowe znalazły się w "ogonie" wykresu (najniższy support). Wniosek ten tłumaczy wcześniejszy ogólny spadek metryk dla modelu 49-klasowego. Sieć neuronowa w obliczu braku wystarczającej reprezentacji skomplikowanych barwowo akordów septymowych "cofa się" do bezpiecznych predykcji, rzutując je na łatwiejsze, znane jej z dużej ilości danych trójdźwięki pokrewne.

## 6.5. Wnioski końcowe

Projekt AI-Chord-Analysis zakończył się sukcesem, dostarczając w pełni funkcjonalny rurociąg uczenia maszynowego zdolny do automatycznego rozpoznawania akordów (ACR) na podstawie surowych plików audio. Przeprowadzone eksperymenty oraz dogłębna analiza metryk pozwalają na sformułowanie następujących wniosków końcowych:

- **Skuteczność autorskiego potoku DSP:** Zastosowanie spektrogramów CQT o podwyższonej rozdzielczości (252 biny) w połączeniu z algorytmem separacji harmoniczno-perkusyjnej (HPSS) okazało się kluczowe do zniwelowania fundamentalnych problemów analizy muzyki, takich jak szumy perkusyjne czy nakładanie się alikwotów.
- **Znaczenie szerokiego kontekstu czasowego:** Zwiększenie analizowanego przez sieć okna czasowego do blisko 8 sekund przyniosło największy pojedynczy skok jakościowy, osiągając skuteczność rzędu 69,53% dla słownika 25 klas. Dowodzi to, że architektura wykorzystująca dwukierunkowe warstwy GRU i mechanizm Attention w pełni wykorzystuje następstwo zdarzeń do prawidłowej diagnozy harmonii.
- **Zrozumienie muzyki przez sieć (Music-Awareness):** Wdrożona funkcja straty oparta na macierzy podobieństwa akordów sprawiła, że pomyłki modelu nie są przypadkowe. Analiza macierzy pomyłek udowodniła, że błędy dotyczą głównie trybów jednoimiennych (np. Em mylone z E) oraz akordów pokrewnych (np. A#m z C#), co jest całkowicie uzasadnione akustycznie w gęstym, polifonicznym miksie.
- **Priorytet generalizacji nad dokładnością testową:** Najważniejszym osiągnięciem inżynierskim zespołu było uodpornienie systemu na błąd statystyczny zbioru (key bias). Rozszerzenie przestrzeni do 49 klas (akordy septymowe) oraz wdrożenie augmentacji przez transpozycję offline naturalnie obniżyło surową dokładność do 47%. Zabieg ten uniemożliwił jednak zjawisko przeuczenia na znanych utworach, wymuszając na sieci rozpoznawanie czystych relacji interwałowych, co czyni model stabilnym narzędziem produkcyjnym.
- **Barier i obszary do poprawy:** Dogłębna analiza wykresów F1 wykazała, że sieć posiada marginalną skuteczność w klasyfikowaniu klasy 'N' (brak akordu / szum), na poziomie około 29% trafności. System wykazuje tendencję do "dopasowywania na siłę" hałasu perkusyjnego do znanych triad. Optymalizacja tego obszaru wymagałaby w przyszłości balansu zbioru treningowego poprzez dostarczenie większej liczby czystych próbek negatywnych.